

Tarea 1: Notebook de análisis exploratorio de datos y Machine Learning básico

Tema:

Análisis exploratorio y modelo básico de Machine Learning para la predicción del riesgo académico estudiantil en entornos virtuales de aprendizaje

Informe individual para el módulo:
MTDI202: Big Data, Analytics & Data Scientist

Presentado por:
Milton Elías Espinoza Villalba

Docente:
Ing. Carlos Wladimir Carrillo Villavicencio MSc. TIC.

Módulo:
MTDI202: Big Data, Analytics & Data Scientist

Quito, junio de 2026

RESUMEN

Este informe presenta un análisis exploratorio de datos y un modelo básico de Machine Learning supervisado aplicado al Open University Learning Analytics Dataset (OULAD), un conjunto de datos público y anonimizado sobre estudiantes, cursos, evaluaciones e interacciones en un entorno virtual de aprendizaje. La problemática analítica se centra en identificar patrones asociados al riesgo académico, entendido como la posibilidad de retiro o reprobación del estudiante. La metodología se desarrolla en Python mediante Google Colab e incluye carga de datos, limpieza, integración de DataFrames, transformación de variables, análisis exploratorio, visualización y modelado predictivo con scikit-learn. La variable objetivo propuesta es riesgo_academico, construida a partir del resultado final del estudiante. El modelo se plantea como una tarea de clasificación supervisada, comparando regresión logística y Random Forest. Los resultados finales, métricas y gráficos deberán actualizarse después de ejecutar el notebook completo. El enfoque permite demostrar cómo la analítica educativa puede apoyar procesos de alerta temprana, intervención académica y mejora continua, sin reemplazar el criterio pedagógico del docente.

Palabras clave: análisis exploratorio de datos; Python; pandas; visualización de datos; Machine Learning; analítica educativa.

DECLARACIÓN DE ACEPTACIÓN DE NORMA ÉTICA Y DERECHOS

El presente informe se ciñe a las normas éticas y reglamentarias de la Universidad Hemisferios. Declaro que el contenido ha sido desarrollado con respeto a los derechos de autor, citando adecuadamente las fuentes utilizadas y manteniendo la confidencialidad de los datos cuando corresponda. El dataset utilizado es público y anonimizado. Asimismo, declaro que los flujos, resultados e interpretaciones presentadas corresponden al desarrollo individual de la actividad, pudiendo haber empleado herramientas de apoyo únicamente para mejorar la documentación, organización o revisión del trabajo.

Firma: _____

Nombre: Milton Elías Espinoza Villalba

C.I.: [Complete su número de identificación]

ÍNDICE

[Actualice el índice automático en Word antes de exportar a PDF.]

1. Introducción
2. Descripción del dataset
3. Descripción de variables y variable objetivo
4. Problemática detectada
5. Marco conceptual
6. Metodología y pipeline del notebook
7. Desarrollo del análisis exploratorio de datos
8. Análisis visual de resultados
9. Machine Learning básico
10. Análisis de resultados obtenidos
11. Conclusiones
12. Recomendaciones
13. Bibliografía
14. Anexos

TÍTULO DEL INFORME

Análisis exploratorio y modelo básico de Machine Learning para la predicción del riesgo académico estudiantil en entornos virtuales de aprendizaje

Autor: Milton Elías Espinoza Villalba

Correo electrónico: [Ingresa correo institucional Universidad Hemisferios]

1. Introducción

La transformación digital de la educación superior ha incrementado la disponibilidad de datos sobre estudiantes, cursos, evaluaciones e interacción en plataformas virtuales de aprendizaje. Estos datos pueden ser analizados mediante técnicas de Data Analytics y Machine Learning para comprender patrones de desempeño y apoyar procesos de toma de decisiones académicas. En este trabajo se utiliza el Open University Learning Analytics Dataset (OULAD), un dataset público y anonimizado, con el propósito de explorar factores asociados al rendimiento académico y construir un modelo básico para clasificar estudiantes con posible riesgo académico.

El análisis se desarrolla en Google Colab con Python, aplicando manejo de DataFrames, limpieza de datos, integración de tablas, análisis exploratorio, visualización e implementación de un modelo supervisado con scikit-learn. La finalidad no es sustituir el criterio docente, sino demostrar cómo la analítica educativa puede convertirse en una herramienta de apoyo para la detección temprana y la intervención académica.

2. Descripción del dataset

El dataset seleccionado es Open University Learning Analytics Dataset (OULAD). Contiene información sobre cursos, estudiantes, evaluaciones e interacciones de estudiantes con un entorno virtual de aprendizaje. Los datos están distribuidos en varios archivos CSV conectados mediante identificadores comunes como code_module, code_presentation e id_student. El dataset es público, anonimizado y adecuado para tareas de clasificación, regresión y análisis exploratorio.

Campo	Descripción
Nombre del dataset	Open University Learning Analytics Dataset (OULAD)
Fuente u origen de los datos	UCI Machine Learning Repository / Open University
Formato del archivo	CSV
Número de registros	Se actualizará después de ejecutar el notebook
Número de columnas	Se actualizará después de ejecutar el notebook
Periodo de análisis	Presentaciones académicas identificadas por módulo y cohorte
Área o dominio	Educación superior, analítica del aprendizaje, educación virtual
Nivel de sensibilidad	Dataset público y anonimizado

3. Descripción de variables, características y variable objetivo

Las variables se organizan en dimensiones demográficas, académicas, evaluativas e interacción digital. La variable objetivo se construye a partir de final_result, agrupando Withdrawn y Fail como riesgo académico, y Pass y Distinction como sin riesgo académico.

Variable	Tipo de dato	Descripción	Rol en el análisis	Observaciones
final_result	Categórica	Resultado final del estudiante	Base para crear variable objetivo	Se transforma en riesgo_academico
riesgo_academico	Clasificación binaria	Indica si el estudiante está en riesgo académico	Objetivo	1 = riesgo; 0 = sin riesgo
total_clicks	Numérica	Total de clics del estudiante en la plataforma	Predictora	Variable derivada de studentVle
avg_score	Numérica	Promedio de calificaciones en evaluaciones	Predictora	Variable derivada de studentAssessment
highest_education	Categórica	Nivel educativo previo	Predictora	Variable demográfica
age_band	Categórica	Rango de edad	Predictora	Variable demográfica
studied_credits	Numérica	Créditos estudiados	Predictora	Variable académica
num_of_prev_attempts	Numérica	Número de intentos previos	Predictora	Variable académica

4. Problemática detectada

En los entornos virtuales de aprendizaje, el riesgo académico puede manifestarse mediante baja interacción, bajo rendimiento en evaluaciones, intentos previos, retiro del curso o reprobación final. El problema central es que estas señales pueden no ser detectadas oportunamente, dificultando la intervención docente o institucional.

Pregunta analítica principal: ¿Es posible clasificar estudiantes con riesgo académico a partir de variables demográficas, académicas, evaluativas y de interacción en un entorno virtual de aprendizaje?

Objetivo general del análisis: desarrollar un análisis exploratorio y un modelo básico de Machine Learning supervisado para identificar estudiantes con posible riesgo académico.

Objetivos específicos:

1. Integrar y preparar los DataFrames del dataset OULAD.
2. Analizar patrones de interacción, evaluación y características estudiantiles.
3. Entrenar y evaluar un modelo básico de clasificación supervisada con scikit-learn.

5. Marco conceptual

La analítica del aprendizaje se enfoca en la medición, recopilación, análisis y reporte de datos sobre los estudiantes y sus contextos, con el propósito de comprender y optimizar el aprendizaje. El dataset OULAD

fue diseñado para apoyar investigaciones sobre comportamiento estudiantil, desempeño académico y aprendizaje en línea (Kuzilek, Hlosta, & Zdrahal, 2017).

El análisis exploratorio de datos permite examinar la estructura, distribución, valores atípicos y relaciones preliminares del dataset antes de aplicar modelos predictivos. En Python, pandas facilita el trabajo con DataFrames, permitiendo limpiar, transformar, agrupar e integrar datos estructurados (McKinney, 2010).

La visualización de datos cumple una función analítica y comunicacional porque permite identificar patrones, comparar grupos y representar relaciones complejas de forma comprensible. En este trabajo se utilizan visualizaciones como histogramas, boxplots, barras, mapas de calor y matrices de confusión.

El Machine Learning supervisado consiste en entrenar modelos a partir de datos etiquetados, donde existe una variable objetivo conocida. Para este caso, la tarea se formula como clasificación binaria, donde el modelo aprende a distinguir estudiantes con riesgo académico y sin riesgo académico mediante scikit-learn (Pedregosa et al., 2011).

6. Metodología y pipeline del notebook

Paso	Fase del pipeline	Descripción aplicada
1	Carga del dataset	Descarga o carga manual del dataset OULAD en Google Colab
2	Revisión de estructura	Uso de head, shape, columns, info, dtypes y describe
3	Limpieza y preparación	Revisión de nulos, duplicados, tipos y consistencia
4	Integración	Unión de tablas con merge mediante llaves comunes
5	Análisis exploratorio	Estadística descriptiva, groupby, crosstab, pivot_table y correlaciones
6	Visualización	Gráficos para variables categóricas, numéricas y temporales relativas
7	Machine Learning	Definición de X/y, train_test_split, fit, predict y métricas
8	Interpretación	Análisis de hallazgos, limitaciones, conclusiones y recomendaciones

Flujograma del pipeline: [Carga de datos] -> [Limpieza] -> [Integración de DataFrames] -> [EDA] -> [Visualización] -> [Modelo ML] -> [Evaluación] -> [Resultados]

7. Desarrollo del análisis exploratorio de datos

El notebook evidencia el uso de métodos de manejo de DataFrames como head, tail, shape, columns, info, dtypes, describe, isnull, duplicated, drop_duplicates, fillna, astype, value_counts, nunique, sort_values, loc, iloc, query, groupby, agg, crosstab, pivot_table, corr y merge. Estos métodos se aplican para comprender la estructura del dataset, preparar variables y generar evidencia analítica.

Los resultados específicos de filas, columnas, valores faltantes, duplicados, agregaciones y correlaciones deberán actualizarse con base en la ejecución real del notebook.

8. Análisis visual de resultados

El notebook propone al menos diez visualizaciones: distribución del resultado final, proporción de riesgo académico, histograma de clics, boxplot de clics por resultado, tasa de riesgo por nivel educativo, tasa de riesgo por edad, violin plot de calificaciones, línea temporal de clics, heatmap de correlación, scatter plot entre clics y promedio de evaluación, barras agrupadas por módulo y matriz de confusión del modelo.

Cada visualización debe acompañarse de una interpretación breve y orientada a la problemática analítica.

9. Machine Learning básico

Elemento	Descripción
Tipo de problema	Clasificación supervisada
Variable objetivo	riesgo_academico
Variables predictoras	Variables demográficas, académicas, evaluativas e interacción digital
Algoritmos seleccionados	LogisticRegression y RandomForestClassifier
División de datos	train_test_split con 80% entrenamiento y 20% prueba
Métricas utilizadas	Accuracy, precision, recall, F1-score, matriz de confusión y ROC AUC cuando aplica
Resultado principal	Se actualizará después de ejecutar el notebook

El modelo se implementa con pipelines de scikit-learn, incorporando imputación, escalamiento de variables numéricas, codificación One-Hot de variables categóricas y entrenamiento del clasificador.

10. Análisis de resultados obtenidos

Resultado	Interpretación	Evidencia
Hallazgo 1	Se actualizará con el EDA	Tabla o gráfico generado
Hallazgo 2	Se actualizará con el EDA	Tabla o gráfico generado
Hallazgo 3	Se actualizará con el EDA	Tabla o gráfico generado
Resultado del modelo ML	Se actualizará con métricas reales	Accuracy, precision, recall, F1-score y matriz de confusión

11. Conclusiones

1. El dataset OULAD es pertinente para la tarea porque contiene datos estructurados, variables categóricas, variables numéricas, dimensión temporal relativa y una variable de resultado académico que permite construir una tarea de clasificación supervisada.

2. La integración de DataFrames permite construir variables analíticas relevantes como total de clics, días activos, promedio de evaluación y número de entregas realizadas, las cuales pueden relacionarse con el riesgo académico.

3. El modelo de Machine Learning debe interpretarse como una herramienta de apoyo a la toma de decisiones educativas, no como un mecanismo automático de juicio sobre el estudiante.
4. Las conclusiones finales deben ajustarse después de ejecutar el notebook y observar las métricas reales del modelo.

12. Recomendaciones

1. Ejecutar el notebook completo en Google Colab y actualizar el informe con las métricas reales del modelo.
2. Usar el recall como métrica especialmente importante, porque en un contexto educativo interesa detectar correctamente a estudiantes en riesgo.
3. Evitar variables que generen fuga de información, como la fecha de retiro del estudiante, cuando el objetivo sea predecir riesgo antes del desenlace final.
4. En futuras versiones, construir modelos con ventanas tempranas del curso para simular un verdadero sistema de alerta temprana.

13. Bibliografía

Kuzilek, J., Hlosta, M., & Zdrahal, Z. (2017). Open University Learning Analytics dataset. Scientific Data, 4, 170171. <https://doi.org/10.1038/sdata.2017.171>

McKinney, W. (2010). Data structures for statistical computing in Python. Proceedings of the 9th Python in Science Conference, 56-61.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, E. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830.

The University of California, Irvine. (2015). Open University Learning Analytics dataset [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5KK69>

14. Anexos

Anexo 1. Enlace público al repositorio de GitHub: [Pegue aquí el enlace cuando cree el repositorio].

Anexo 2. Enlace al notebook en Google Colab: [Pegue aquí el enlace público o de visualización].

Anexo 3. Evidencias de ejecución del notebook: [Inserte capturas o resultados principales].